

임무 중심 드론 초분광 영상 전송을 위한 Autoencoder Bottleneck 압축 프레임워크

익명 저자

국문 초록

드론 기반 초분광 영상은 연안 감시, 항만 방호, 위장 표적 탐지, 해상 부유물 탐지와 같은 해군 임무에서 물질 고유의 분광 차이를 활용할 수 있다는 장점이 있다. 그러나 초분광 영상은 하나의 장면이 공간 정보와 수십에서 수백 개의 연속 밴드를 함께 포함하는 3차원 큐브 형태이므로, 원시 데이터 전체를 드론에서 지상국으로 실시간 전송하기 어렵다. 특히 소형 드론은 탑재 중량, 전력, 연산 자원, 통신 대역폭이 모두 제한되기 때문에 모든 패치와 밴드를 동일한 중요도로 송신하는 방식은 운용 효율성이 낮다. 본 연구는 이러한 문제를 해결하기 위해 Autoencoder 기반 잠재표현 압축과 임무지향 패치 선택을 결합한 선택적 전송 구조를 검토한다. 제안 구조는 초분광 큐브를 공간 패치로 분할하고, 제한된 전송 예산에서 random, edge_only, spectral_only 기준으로 우선 전송 패치를 선택한 뒤, 선택된 패치의 latent payload만 전송한다. KSC와 Salinas 공개 데이터셋을 이용한 3개 seed 반복 실험 결과, spectral_only는 여러 budget 조건에서 random 및 edge_only보다 높은 important precision과 important recall을 보였다. 또한 latent payload 기준으로 KSC 약 613.0배, Salinas 약 710.5배의 byte 감소 가능성을 확인하였으며, 40 Mbps 및 100 Mbps급 링크에서 ms 단위 전송이 가능한 크기로 축소되었다. 본 연구는 초분광 압축을 단순 복원 화질 문제가 아니라 제한된 통신 예산에서 임무 관련 정보를 우선 전달하는 문제로 재정의한다.

주제어 : 초분광 영상, 오토인코더, 드론, 임무지향 압축, 선택 전송, 연안 감시

논문 활용 분야

본 연구는 해군 연안 감시, 항만 방호, 위장 표적 탐지, 해상 부유물 탐지 및 수색·구조 지원 임무에서 드론 초분광 센서가 생성하는 대용량 데이터를 제한된 전술 통신 환경에서 효율적으로 전달하는 데 활용될 수 있다. 적용 부대는 함정 기반 지휘통제소, 해안 감시부대, 무인기 운용부대, 항만 방호부대 및 해양환경 감시부대로 설정할 수 있다. 제안 구조는 원시 초분광 큐브 전체를 지속적으로 전송하는 대신, 스펙트럼 변동성이 큰 중요 후보 패치의 잠재표현을 우선 전송함으로써 통신 대역폭 부담을 줄이고 임무상 필요한 정보를 먼저 확보하도록 지원한다. 이를 통해 지상국 또는 함정 지휘소는 표적 후보 영역, 구조물 이상 징후, 부유물 및 오염 의심 구역을 신속히 확인하고, 필요 시 해당 영역의 추가 정밀 전송 또는 재탐색을 요청할 수 있다. 기대효과는 제한된 링크 환경에서 초분광 영상의 실시간 또는 준실시간 활용 가능성을 높이고, 감시·정찰 판단의 신속성과 통신 지속성을 향상시키는 것이다.

I. 서론

1.1 연구 배경

초분광 영상은 픽셀마다 수십~수백 개의 연속 분광 밴드를 포함하므로 RGB 영상으로 구분하기 어려운 물질 고유의 반사 특성을 관측한다. 이 특성은 연안 감시, 항만 감시, 위장 표적 식별, 해상 부유물 탐지처럼 재질 정보가 중요한 드론 임무에 유용하다[1].

해군 연안 작전환경에는 항만 구조물, 해안 식생, 소형 선박, 부유물, 어망, 저수심 해저 반사, 수면 반사, 탁도와 파랑이 공존한다. CHROMA 실험은 초분광 영상과 AI를 결합한 환경정보 임무를 제시했고[2], 해상 표면 감시 분석은 소형 표적, 혼잡 배경, AIS 조작 가능성 때문에 단일 센서의 한계를 보고하였다[3].

핵심 제약은 데이터량이다. 초분광 큐브는 밴드 수만큼 저장량과 전송량이 증가하므로 드론에서는 저장장치, 연산량, 전력, 통신 대역폭 부담이 동시에 발생한다. UAV용 HSI 원시 데이터율은 수백 Mbps~Gbps에 이를 수 있으나 일반 드론 링크와 소형 데이터링크는 수십~100 Mbps급에 머무르는 경우가 많아 실시간 전체 송신이 어렵다.

1.2 연구 목적과 논문 구성

본 논문은 원시 큐브 전체 송신 대신 Autoencoder 잠재표현(latent representation)을 선택적으로 전송하는 임무지향 통신압축 구조를 제안한다. 목표는 전체 평균 복원 화

질이 아니라 제한된 전송 예산에서 정찰상 중요한 영역의 복원 가능성과 전송량 절감 효과를 동시에 확보하는 것이다.

본 연구는 제한 예산에서 어떤 패치를 먼저 송신해야 하는지에 초점을 두고, Autoencoder latent가 정보성 높은 패치를 우선 포함할 수 있는지를 공개 benchmark로 검증한다. 평가는 전체 평균 복원 품질보다 budget별 important precision/recall에 둔다. KSC·Salinas에서 스펙트럼 분산, 공간 edge, 무작위 기준선을 비교하고, 선택패치의 GT 중요패치 포함률을 분석한다. 상세 budget 표·그림, payload 전송시간, CUDA 보조 실험은 부록에 두고 본문은 방법·핵심 해석·운용 의미를 중심으로 서술한다.

II. 초분광 영상 통신압축의 연구 배경

2.1 드론 초분광 영상의 데이터량 문제

초분광 영상은 $H \times W \times B$ 의 3차원 구조를 가지며, 밴드 수 B 가 늘수록 저장량과 전송량도 선형적으로 증가한다. 드론에서는 센서 탑재뿐 아니라 후단 처리장치, 저장장치, 통신장치 부담을 함께 고려해야 한다.

UAV용 HSI 센서의 데이터율은 일반 드론 링크를 초과하기 쉽다. Headwall Nano-Hyperspec은 640 spatial samples, 270 bands, 12-bit, 최대 350 Hz를 제시하며[23], 100 fps 환산 시 약 207 Mbps이다. Specim AFX10은 1024 spatial pixels, 최대 224 bands, 최대 100~150 fps의 UAV용 VNIR HSI로[24], 약 215~413 Mbps이다.

반면 DJI Transmission/O3/O4의 최대 video bitrate는 40/50/130 Mbps이고[25], Microhard pDDL900은 최대 25 Mbps Iperf throughput을 제시한다[26]. Silvus StreamCaster 4200도 100+ Mbps adaptive data rate를 제시하나[27], 원시 HSI의 지속 실시간 전송에는 병목이 남는다.

전술 운용에서는 모든 데이터를 동일 중요도로 전송할 필요가 없다. 넓은 해상 배경과 식생보다 표적 후보, 구조물 경계, 이질적 스펙트럼 영역이 임무 판단에 더 중요할 수 있다. 따라서 전송 전략은 전체 화질 평균보다 중요 영역 정보 보존을 우선해야 한다.

기존 영상 압축은 시각 품질 또는 전체 평균 왜곡을 주로 최적화한다. 그러나 초분광 정찰에서는 RGB 렌더링보다 스펙트럼 곡선, 물질 간 분광 차이, 표적 후보 식별 가능성이 더 중요하다. 본 연구도 제한 예산에서 GT 기준 중요패치를 얼마나 먼저 포함하는지를 중심으로 평가한다.

2.2 연안 환경에서의 초분광 감시 연구

연안 해저 재질 분석 연구는 수심, 수체 산란·흡수에 따라 반사도가 달라져 분류 전 보

Table 1. 실제 UAV용 초분광 센서 원시 데이터율과 대표 드론 통신 링크의 전송률 비교.

구분	장비/링크	주요 스펙	전송률	해석
HSI 센서	Headwall Nano-Hyperspec	640 spatial × 270 bands, 12-bit, 100 fps 환산	약 207 Mbps	일반 40-50 Mbps 영상 링크 초과
HSI 센서	Specim AFX10	1024 spatial × 224 bands, 12-bit, 100~150 fps 환산	약 275~413 Mbps	100 Mbps급 링크도 크게 초과
드론 영상 링크	DJI Transmission / O3 / O4	제조사 최대 bitrate 기준	40 / 50 / 130 Mbps	압축 영상 전송에는 적합하나 원시 HSI에는 부족할 가능성
UAV 데이터링크	Microhard pDDL900	1perf throughput	최대 25 Mbps	저대역 장거리 링크 조건
Tactical MANET	Silvus StreamCaster 4200	Adaptive data rate	100+ Mbps	고성능 링크이나 원시 HSI 센서율에는 여전히 제한적

정이 필요하다고 보고하였다[5]. 연안 인공 구조물 녹조 분류 연구는 초분광 영상과 딥러닝이 기존 SVM보다 정밀한 객체 분류를 가능하게 함을 보였다[6]. 이는 초분광 가치가 고분해능 영상 자체보다 복잡 배경 속 물질·상태·이상 징후 분리에 있음을 시사한다.

해상 표적 탐지에서 초분광과 딥러닝의 결합 가능성이 확인된다. 항공 초분광 해상 감시에서 3D CNN은 spectral angle mapper 및 derivative anomaly detection보다 표적 클래스별 재현율을 개선하였다[7]. 소형 부유체 연구는 선박, 구멍부환, 부력장치, 마네킹 탐지를 보였고[8], 최근 연구는 실시간 분석 가능성과 함께 데이터 불균형·라벨 부족을 지적하였다[9].

2.3 학습 기반 압축과 의미론적 통신

전통적 초분광 압축에서는 CCSDS 123.0-B-2 같은 저복잡도 무손실·근무손실 표준이 기준선이다[10]. 최근 HySpecNet-11k는 학습 기반 압축 benchmark를 제공하고[11], HyCoT는 transformer 기반 Autoencoder로 공간·스펙트럼 의존성을 학습한다[12]. Line-based attention 예측 코딩도 탑재형 압축 가능성을 확장한다[13].

모든 밴드가 모든 임무에 동일하게 유효하지는 않다. 일부 밴드는 재질 차이를 드러내지만, 일부는 대기 흡수, 잡음, 수면 반사로 성능을 낮춘다. Task-driven band selection은 분류 손실 기반 밴드 선택을[14], graph learning 기반 Autoencoder는 대표성과 안정성이 높은 밴드 선택을 제안하였다[15].

의미론적 통신은 압축 목적을 재구성 충실도에서 임무 관련 정보 전달로 확장한다. Autoencoder 기반 task-oriented semantic communication은 임무 성능 중심 전송

을[16], feature-importance-aware transmission은 중요한 특징 우선 전송을 제안하였다[17]. 이는 HSI에서도 임무 관련 패치와 latent를 우선 전송하는 구조를 뒷받침한다 [18-21].

본 연구는 EHU Hyperspectral Remote Sensing Scenes 포털에서 제공하는 KSC와 Salinas 공개 초분광 장면을 사용하였다. 실험에서는 각 장면의 GT 라벨 정보는 선택 결과를 평가하기 위한 중요 패치 정의에만 활용하였다.

Table 2. 본 연구에서 사용하는 공개 초분광 데이터와 평가 목적.

구분	내용	평가 목적
Salinas	Salinas 초분광 장면	공간-스펙트럼 패턴이 뚜렷한 공개 benchmark에서 제한 예산 전송 평가
KSC	Kennedy Space Center 초분광 장면	해안성 습지 장면에서 제한 예산 전송 평가

이상의 선행연구는 초분광 압축과 전송이 단순한 데이터 축소 문제가 아니라, 임무 목적과 연계된 정보 선택 문제로 확장될 수 있음을 보여준다. 원시 큐브 전송은 정보 손실이 없지만 드론 통신 환경에서는 대역폭과 지연 부담이 크고, CCSDS 계열 압축은 표준성과 안정성이 높으나 임무 중요도 기반 우선 전송에는 한계가 있다. 또한 재구성 중심 Autoencoder는 평균 복원 품질 향상에 유리하지만, 감시·정찰 임무에서 요구되는 중요 정보 전달 목적과 항상 일치하지는 않는다. 이에 본 연구는 제한된 통신 예산에서 임무상 중요한 패치의 latent를 우선 전송하는 선택적 전송 구조를 검토한다. KSC와 Salinas 장면을 대상으로 random, edge_only, spectral_only 기준을 비교하고, GT 기준 중요 패치 포함 여부를 important precision과 important recall로 평가한다.

III. 임무지향 선택적 잠재표현 전송 방법

3.1 전체 처리 절차

제안 구조는 드론에서 획득한 HSI 큐브를 공간 패치로 나누고, 패치 중요도를 계산한 뒤 예산 내 일부 패치의 latent만 송신한다. 수신단은 해당 latent를 복원하거나 latent 기반 판단을 수행하므로, 원시 전체 영상 대신 중요한 패치에 통신 자원을 집중한다.

처리 경로는 raw patch, encoder, latent z, quantization, payload accounting, dequantization, decoder, reconstructed patch 순서이다. 원시 패치는 latent z로 변환되고 8-bit 양자화 뒤 전송 byte가 계산된다. 수신 측에서는 dequantization과 decoder 복원 후 겹치는 패치를 평균 결합한다. 양자화 수준 최적화는 범위에서 제외하였다.

Fig. 1. 임무지향 선택적 latent 전송 구조. 온보드에서 HSI 큐브를 패치화하고, GT label 비사용 중요도 기준으로 selected latent와 좌표만 전송한 뒤, 지상국에서 복원 및 important




Fig. 1의 흐름은 “드론 HSI 획득 → 패치 분할 → 중요도 평가 → AE Encoder → Latent:좌표 우선 전송 → 수신단 복원·분석”이다. 이는 raw cube transmission을 피하고 중요패치의 latent payload를 먼저 전달한다.

3.2 중요도 기반 패치 선택

패치 선택 기준은 GT 라벨을 직접 사용하지 않는 비GT 기준선으로 구성하였다. random은 임무 정보 없이 전송 예산만 제한한 기준선이고, edge_only는 공간 경계가 강한 패치를, spectral_only는 스펙트럼 변동성이 큰 패치를 우선 전송한다. ae_full은 선택 전송을 적용하지 않고 전체 test patch의 latent를 모두 전송하는 상한 기준으로 사용하였다.

spectral_only와 edge_only는 최종 학습 선택기가 아니라 단순하고 재현 가능한 휴리스틱 기준선이다. 이 설정의 목적은 제한된 전송 budget에서 공간 경계 정보와 스펙트럼 변동성 중 어떤 단서가 GT coverage 기준 important patch를 더 잘 포함하는지 비교하는 데 있다. 전송 우선순위 산정에는 실제 표적 라벨을 사용하지 않고, GT 라벨은 선택 결과를 평가하는 단계에서만 사용하였다.

패치 P_i 의 spectral score는 패치 내 각 픽셀의 밴드 축 분산을 공간 평균한 값으로 정의한다.

$$s_{spec}(P_i) = \frac{1}{hw} \sum_{u=1}^h \sum_{v=1}^w Var_b(x_{i,u,v,b})$$

edge score는 밴드 평균 영상에 Sobel 연산을 적용하여 계산한 edge magnitude의

공간 평균으로 정의한다. 먼저 패치 P_i 의 밴드 평균 영상 $\overline{X}_i$ 는 다음과 같다.

$$\overline{X}_i(u, v) = \frac{1}{L} \sum_{b=1}^L x_{i,u,v,b}$$

이를 이용한 edge score는 다음과 같이 계산한다.

$$s_{edge}(P_i) = \frac{1}{hw} \sum_{u=1}^h \sum_{v=1}^w \sqrt{(G_x * \overline{X}_i)_{u,v}^2 + (G_y * \overline{X}_i)_{u,v}^2}$$

여기서 P_i 는 i 번째 초분광 패치, h 와 w 는 패치의 공간 크기, L 은 밴드 수, $x_{i,u,v,b}$ 는 패치 내 위치 (u, v) 의 b 번째 밴드 값을 의미한다. $\overline{X}_i$ 는 밴드 평균 영사이며, G_x 와 G_y 는 각각 x 축 및 y 축 Sobel 필터이다. 따라서 spectral_only는 패치 내 밴드 방향 분산의 공간 평균을 중요도 점수로 사용하고, edge_only는 밴드 평균 영상의 Sobel edge magnitude 평균을 중요도 점수로 사용한다.

전송 budget B 가 주어지면 전체 test patch 수 N 중 $K_B = \lfloor BN \rfloor$ 개를 선택한다. random은 K 개 패치를 무작위로 선택하고, edge_only와 spectral_only는 각각의 중요도 점수가 큰 순서대로 K 개 패치를 선택한다.

$$S_B = TopK(s(P_i), K = \lfloor BN \rfloor)$$

본 연구의 important patch는 실제 해상 표적 ROI가 아니라 공개 데이터셋의 GT label coverage를 이용해 정의한 대리 지표이다. GT label coverage는 패치 내에서 GT 라벨이 존재하는 픽셀 비율로 정의하였다.

$$c(P_i) = \frac{1}{hw} \sum_{u=1}^h \sum_{v=1}^w I(y_{i,u,v} > 0)$$

여기서 $y_{i,u,v}$ 는 패치 P_i 의 위치 (u, v) 에서 GT label 값을 의미하며, $I(\cdot)$ 는 조건이 참이면 1, 거짓이면 0을 반환하는 지시함수이다. 본 연구에서는 $C(P_i)$ 가 높은 상위 패치를 important patch로 정의하였다.

$$S_B = TopM(C(P_i), M = \lfloor \rho N \rfloor)$$

여기서 G 는 GT coverage 기준 important patch 집합, N 은 전체 test patch 수, ρ 는 important patch 비율이다. 본 실험에서는 $\rho \approx 0.25$ 로 설정하여 Salinas에서는 test patch 286개 중 상위 72개를, KSC에서는 test patch 825개 중 상위 207개를 important patch로 정의하였다.

important precision과 important recall은 군사 표적 탐지 성능이 아니라, 제한된 budget에서 라벨 정보가 풍부한 패치를 얼마나 우선 포함하는지를 나타내는 지표로 해석해야 한다. 두 지표는 다음과 같이 정의한다.

$$\text{Recall}_B = \frac{|S_B \cap G|}{|G|}, \quad \text{Precision}_B = \frac{|S_B \cap G|}{|S_B|}$$

즉, Recall_B 는 important patch 중 선택된 패치의 비율을, Precision_B 는 선택된 패치 중 important patch에 해당하는 비율을 의미한다.

3.3 중요도 기반 패치 선택

제안 구조는 픽셀 충실도 중심 최적화를 임무 효율 중심 최적화로 전환하는 데 출발점이 있다. 손실함수는 복원 오차뿐 아니라 표적 탐지·식별, ROI 재구성, 스펙트럼 각도 보존, 전송률, 마스크 희소성, 조건 변화 일관성을 함께 고려하도록 확장할 수 있다.

$$L = \lambda_{task}L_{task} + \lambda_{rec}L_{ROI,rec} + \lambda_{spec}L_{spectral} + \lambda_{rate}R(z) + \lambda_{sparse}||m||_1 + \lambda_{stab}L_{consistency}$$

여기서 L_{task} 는 탐지·식별·이상탐지 손실, $L_{ROI,rec}$ 는 관심영역 저울 재구성 손실, $L_{spectral}$ 은 스펙트럼 형태 보존, $R(z)$ 는 비트율 또는 token budget, $||m||_1$ 은 선택 희소성, $L_{consistency}$ 는 조건 변화 예측 일관성이다. 본 논문은 구조 검증에 초점을 두므로 이 손실함수는 확장 설계 방향으로 제시한다.

운용개념은 임무 정의 후 전송의 원칙에 기반한다. 항만 감시는 선체 재질·도장 이질성·구조물 경계, 수색·구조는 부유 소형체·구명장비, 환경감시는 유해물질·조류·구조물 표면 상태를 우선 정보로 삼는다. 따라서 우선 전송 밴드와 영역은 임무별로 달라진다.

Table 3. 임무별 우선 전송 정보와 수신단 활용 예.

임무	우선 전송 정보	수신단 활용
항만 감시	선체 재질, 도장 이질성, 구조물 경계	표적 후보 식별 및 재요청 판단
위장 표적 탐지	주변 배경과 다른 분광 곡선, 경계 패치	위장 여부 판단 및 정밀 복원
수색·구조	소형 부유체, 구명장비 후보 영역	고속 후보 탐지 및 위치 보고
환경 이상 감시	오염물, 조류, 구조물 열화 패턴	이상탐지 및 변화 감시

IV. 실험 설정 및 결과 분석

4.1 실험 설정과 평가 지표

검증 실험은 KSC·Salinas를 대상으로 seed 0, 1, 2의 3회 반복으로 수행하였다. 조건은 epochs=30, quant_bits=8, latent_channels=16이다. 전송 예산은 송신 test patch 비율이며, budget=0.25는 후보 patch의 25% 전송을 뜻한다. 미전송 영역은 train-region mean spectral vector로 채워 숨겨진 원본 정보 접근을 막았다.

평가는 제한 budget에서 GT 기준 중요패치 우선 포함에 둔다. important recall은 GT important patch 중 선택 비율, important precision은 선택 patch 중 GT important patch 비율이다. KSC는 825개 중 207개, Salinas는 286개 중 72개를 important patch로 두고, 표준편차가 0.0005 미만이면 평균만 표기하였다.

Table 4. 압축·복원·임무·운용·견고성 관점의 성능평가 지표 체계.

구분	세부 지표	목적
압축 성능	compression ratio, bpppb, transmitted bytes	전송량 감소 및 비트 예산 확인
복원 성능	PSNR, SSIM, SAM	공간·스펙트럼 복원 품질 확인
임무 성능	important precision, important recall	제한 budget에서 중요패치 포함 여부 평가
운용 성능	latency, memory, power, throughput	드론 탑재 및 전송 링크 적용 가능성 평가
견고성	packet loss sensitivity, domain shift delta	재밍·링크 손실·환경 변화 대응성 평가

4.2 데이터셋 특성과 Autoencoder 복원 성능

KSC는 512×614×176 해안성 습지 장면으로 수계·식생·경계가 혼재해 연안 감시 대리 장면으로 사용하였다. Salinas는 512×217×204의 농업 장면으로 분광 대비와 구조적 경계가 뚜렷해 선택 규칙의 민감도를 확인하기에 적합하다. 두 장면 모두 patch size 16, stride 8, train/val/test y split 6:2:2를 적용하였다.

Table 5. KSC 및 Salinas의 30 epoch 학습 결과 및 압축 효율

구분	Train loss	Val loss	ae_full PSNR(dB)	ae_full SAM(°)	latent payload
KSC	0.002982	0.001135	24.607 ± 0.052	14.985 ± 0.942	613.0x
Salinas	0.001008	0.001255	24.097 ± 0.070	5.362 ± 0.099	710.5x

30 epoch 학습에서 ae_full 전체 test region PSNR/SAM은 KSC 24.61 ± 0.05 dB / 14.99 ± 0.94°, Salinas 24.10 ± 0.07 dB / 5.36 ± 0.10°였다. Salinas는 스펙트럼

보존이 양호했고, KSC는 경계·수계 영역의 격자성 복원과 저대비가 남았다. ae_full은 선택 전송 제거 상한이다.




Fig. 2. KSC·Salinas의 original 및 ae_full 복원 예. KSC는 격자성 복원이 남고, Salinas는 주요 구조를 보존하나 세부 질감이 완만해진다.

4.3 중요패치 선별 결과

KSC에서는 spectral_only가 제한 budget에서 가장 안정적이었다. budget=0.10의 important precision/recall은 0.277/0.111로 random-edge_only보다 높았고, budget=0.25에서도 0.266/0.266으로 가장 높았다. budget=0.50의 recall은 0.614까지 증가하였다. 이는 스펙트럼 변동성이 KSC important patch 포착에 유효함을 보이며, 전체 수치는 부록 A에 제시하였다.

KSC random baseline도 비교적 강했다. budget=0.10 precision은 0.269 ± 0.007 로 spectral_only와 차이가 작았다. 이는 GT important patch가 전체의 약 25.1%라 무작위 선택도 일정 hit를 내기 때문이다. edge_only는 낮은 budget에서 약했으나 budget=0.75에서는 spectral_only와 recall 0.778로 같았다.

Salinas에서는 spectral_only 우위가 더 컸다. budget=0.10의 precision/recall은 0.448/0.181로 random과 edge_only보다 높았고, budget=0.50에서는 0.455/0.903까지 증가하였다. budget=0.75에서는 recall 1.000에 도달하였다. 이는 GT coverage가 높은 패치가 공간 edge보다 스펙트럼 변동성과 강하게 연관됨을 시사하며, 전체 수치는 부록 B에 제시하였다.

edge_only는 Salinas에서 낮았다. budget=0.10의 precision/recall은 모두 0.000, budget=0.50의 recall은 0.236에 머물러 공간 경계 단서만으로는 GT important patch 포착이 제한적이었다.

4.4 벤치마크 해석 및 논의

두 데이터셋에서 spectral_only는 가장 강한 선택 기준이었다. Salinas에서는 random-edge_only 대비 격차가 컸고, KSC에서도 budget=0.50까지 최고 precision/recall을 보였다. 이는 스펙트럼 변동성이 GT 기준 중요패치 포착에 직접적 단서가 될 수 있음을 의미한다.

ae_full은 전체 test patch 전송 상한이므로 budget=1.00에만 제시하였다. recall은 1.000이나 precision은 KSC 0.251, Salinas 0.252로, 중요패치 선별 방법이 아니라 전체전송 기준선이다. 선택적 전송의 핵심은 제한 budget에서 precision/recall을 함께 높이는 것이다.

한편 ae_full은 전체 latent 전송 조건에서도 KSC 세부 질감과 국소 대비를 완전히 회복하지 못해, 30 epoch 고정 학습·lc=16·q=8·장면 복잡도가 결합된 underfitting 가능성을 시사한다. 따라서 ae_full은 최적 HSI 압축 코덱 성능 상한이 아니라 동일 AE 조건에서 선택 전송을 제거한 비교 기준선이다.

4.5 압축 효율과 전송 통신 관점의 의미

KSC의 compression_ratio_bytes는 약 613.0x, bpppb는 0.0522이며, Salinas는 각각 약 710.5x와 0.0450이다. 이는 원시 float32 patch tensor 대비 latent 기반 8-bit 양자화 전송의 byte 비용이 낮음을 의미한다.

compression_ratio_bytes는 실험 파이프라인의 원시 float32 patch tensor 대비 latent payload byte 감소율이다. 12-bit packed sensor raw, 16-bit DN 영상, packet header, error correction, 암호화, 재전송, 무선 채널 손실을 포함한 실제 bitstream 압축률과 구분되며, 본 논문에서는 실험적 latent payload 기준 전송량 감소 가능성으로 해석한다.

전송 링크는 고속이 보장되지 않으며 품질 급변과 재밍 가능성이 있다. 따라서 원시 큐브 전체 송신보다 임무 관련 ROI와 latent를 먼저 보내고, 추가 확인 시 해당 패치의 원시 또는 저압축 데이터를 재요청하는 구조가 적절하다. 이는 데이터 중심 전송을 임무 중심으로 전환한다.

Headwall Nano-Hyperspec 100 fps 환산은 약 207 Mbps, Specim AFX10 12-bit

full-frame 환산은 약 0.91 Gbps이다. 반면 DJI 링크는 40~130 Mbps, Microhard pDDL은 약 25 Mbps, Silvus StreamCaster는 100 Mbps급 adaptive throughput이므로 원시 HSI 전체 실시간 전송은 제약된다.

압축 latent payload를 40/100 Mbps 링크에 대입하면 KSC·Salinas 선택 전송 payload는 수 ms~수십 ms 이내 전송 가능하다. packet overhead와 재전송을 제외한 계산이나, 원시 큐브 전체전송보다 실시간·준실시간 운용 기반을 보인다.

4.6 CUDA 기반 AE codec path 순수 연산 지연시간 보조 실험

AE codec path의 순수 추론 시간을 CUDA 환경에서 측정하여 연산 부담을 예비 확인하였다. 이 실험은 드론 end-to-end 지연시간이 아니라 encoder, quantization, dequantization, decoder의 모델 경로 계산 비용을 분리한 보조 실험이다.

실험은 Google Colab Tesla T4 CUDA 환경에서 수행하였다. 입력은 KSC와 동일한 176개 밴드, 16×16 크기의 synthetic hyperspectral patch이며, 조건은 latent channel 16, 8-bit 양자화이다. 측정 경로는 encoder, quantization, dequantization, decoder 전체 추론 경로이다. 디스크 I/O, 센서 입력, 패치 추출, 링크 스케줄링, packet loss, 암호화, 재전송은 제외하고 모델·codec 연산 지연시간과 CUDA 메모리만 확인하였다.

batch size 64에서 21,832.51 patches/s, 0.0458 ms/patch, peak memory 65.35 MB가 측정되었다. 모든 batch size에서 10 ms/patch 기준을 만족해 GPU 환경에서 AE codec path 연산 부담이 작음을 보였다. 세부 수치는 부록 D에 제시하였다.

V. 결론

5.1 한계점

본 연구의 한계는 명확하다. 첫째, 실험은 실제 해상 표적 ROI가 아니라 KSC와 Salinas 공개 benchmark의 GT coverage를 이용해 정의한 important patch에 기반한다. 따라서 important precision과 important recall은 군사 표적 탐지 성능이 아니라 라벨 정보가 풍부한 패치를 제한 budget에서 얼마나 우선 포함하는지를 나타내는 대리 지표로 해석해야 한다. 둘째, 본 연구는 실제 탐지 head와 결합한 end-to-end 임무 성능을 검증하지 않았으며, CCSDS 계열 압축이나 entropy coding을 포함한 실제 bitstream 수준의 코덱 비교도 수행하지 않았다. 셋째, 통신 성능은 latent payload 크기를 40 Mbps 및 100 Mbps 링크에 대입한 이상적 전송시간 계산에 기반하며, packet loss, header overhead, 암호화, 재전송 및 링크 품질 변화는 반영하지 않았다. 넷째,

탐재성 검토는 Tesla T4 환경의 compute-only latency 측정에 한정되므로, 실제 드론 탑재 성능으로 일반화하기 위해서는 Jetson Orin 계열 장치에서 센서 입력, 패치 추출, 전력, 발열, 무선 전송을 포함한 end-to-end 검증이 필요하다.

5.2 결론

본 논문은 드론 HSI 원시 데이터 전체전송 문제를 완화하기 위해 Autoencoder latent 전송과 중요패치 선택을 결합한 통신압축 구조를 검토하였다. UAV용 HSI 센서 원시 데이터율은 수백 Mbps~Gbps에 이를 수 있어 일반 드론 영상 링크와 UAV 데이터링크를 초과한다.

KSC·Salinas 3 seed 실험에서 spectral_only는 여러 budget에서 random-edge_only보다 높은 important precision/recall을 보였다. KSC budget=0.50 recall은 0.614로 random 0.488 $\pm$ 0.046보다 높았고, Salinas는 0.903으로 random 0.486 $\pm$ 0.050보다 크게 높았다. 이는 스펙트럼 변동성이 정보 패치 선별에 효과적임을 시사한다.

압축 효율은 KSC 약 613.0x, Salinas 약 710.5x의 실험적 latent payload byte 감소로 나타났고, payload는 40/100 Mbps 링크에서 수 ms~수십 ms 수준으로 전송 가능하였다. CUDA 보조 실험도 0.0458 ms/patch와 65.35 MB peak memory를 보여 선택 전송 가능성을 뒷받침하였다.

한계도 명확하다. 본 연구는 실제 해상 표적이 아니라 KSC·Salinas의 GT coverage 기반 important patch에 의존한다. 실제 탐지 head와 결합한 end-to-end 임무 성능, CCSDS 압축 비교, Jetson 온보드 실측, 무선 손실·재전송 조건도 포함하지 않았다. 따라서 본 결과는 실운용 입증에 아니라 정보성 패치 우선 포함을 보인 구조 검증이다.

부록

부록 A. KSC 중요패치 선별 결과




Fig. A1. KSC budget별 important precision 및 recall 변화. random은 3 seed 평균±표준편차, edge_only와 spectral_only는 deterministic 기준선이다.

Table A1. KSC 3 seed 결과 요약(epochs=30, q=8, lc=16).

budget	전송 패치	방법	Important Precision	Important Recall
0.10	83	random	0.269 ± 0.007	0.108 ± 0.003
		edge_only	0.205	0.082
		spectral_only	0.277	0.111
0.25	207	random	0.261 ± 0.022	0.261 ± 0.022
		edge_only	0.198	0.198
		spectral_only	0.266	0.266
0.50	413	random	0.245 ± 0.023	0.488 ± 0.046
		edge_only	0.264	0.527
		spectral_only	0.308	0.614
0.75	619	random	0.251 ± 0.007	0.752 ± 0.020
		edge_only	0.260	0.778
		spectral_only	0.260	0.778
1.00	825	ae_full	0.251	1.000

부록 B. Salinas 중요패치 선별 결과

Fig. A2. Salinas budget별 important precision 및 recall 변화. spectral_only는 budget=0.75에서 recall 1.000에 도달하였다.




Table A2. Salinas 3 seed 결과 요약(epochs=30, q=8, lc=16).

budget	전송 패치	방법	Important Precision	Important Recall
0.10	83	random	0.276 $\pm$ 0.060	0.111 $\pm$ 0.024
		edge_only	0.000	0.000
		spectral_only	0.448	0.181
0.25	207	random	0.287 $\pm$ 0.008	0.287 $\pm$ 0.008
		edge_only	0.028	0.028
		spectral_only	0.361	0.361
0.50	413	random	0.245 $\pm$ 0.025	0.245 $\pm$ 0.025
		edge_only	0.119	0.236
		spectral_only	0.455	0.903
0.75	619	random	0.253 $\pm$ 0.005	0.755 $\pm$ 0.016
		edge_only	0.140	0.417
		spectral_only	0.335	1.000
1.00	825	ae_full	0.252	1.000

부록 C. KSC 및 Salinas latent payload 전송시간 추정

Table A3. Salinas 3 seed 결과 요약(epochs=30, q=8, lc=16).

데이터셋	budget	압축된 크기	40 Mbps 기준	100 Mbps 기준
KSC	0.10	24,402 byte	약 4.9 ms	약 2.0 ms
	0.25	60,858 byte	약 12.2 ms	약 4.9 ms
	0.50	121,422 byte	약 24.3 ms	약 9.7 ms
	0.75	181,986 byte	약 36.4 ms	약 14.6 ms
	1.00	242,550 byte	약 48.5 ms	약 19.4 ms
Salinas	0.10	8,526 byte	약 1.7 ms	약 0.7 ms
	0.25	21,168 byte	약 4.2 ms	약 1.7 ms
	0.50	42,042 byte	약 8.4 ms	약 3.4 ms
	0.75	63,210 byte	약 12.6 ms	약 5.1 ms
	1.00	84,084 byte	약 16.8 ms	약 6.7 ms

부록 D. CUDA 기반 AE codec path 추론 지연시간

Table A4. CUDA 기반 AE codec path 추론 지연시간 측정 결과.

Batch size	처리량(patch/s)	지연시간(ms/patch)	최대 CUDA 메모리(MB)
8	7,234.30	0.1382	7.57
16	16,198.43	0.0617	19.69
32	21,275.66	0.0470	34.68
64	21,832.51	0.0458	65.35

Google Colab Tesla T4, PyTorch 2.10.0+cu128, CUDA, warmup 30회, 측정 200회. peak memory는 torch.cuda.max_memory_allocated 기준이다.

참고문헌

- [1] Hong, D., Li, C., Yokoya, N., Zhang, B., Jia, X., Plaza, A., Gamba, P., Benediktsson, J. A., & Chanussot, J. (2026). Hyperspectral imaging. Nature Reviews Methods Primers, 6, 19.
- [2] Pasquini, N. E. M. (2026, January 7). Naval Research Lab sharpens Navy's sights with a domain-centric path for smarter sensing. U.S. Naval Research

Laboratory.

- [3] Charbonneau, D. (2018). Maritime surface surveillance scientometric study (Contract Report DRDC-RDDC-2018-C007). Defence Research and Development Canada.
- [4] McManus, M. A., Hochberg, E. J., Joyce, K., Palacios, S. L., Vander Woude, A., Schar, D., Ackleson, S., Anstee, J., Dierssen, H., Garcia, R., Hestir, E., Howse, J., Kudela, R., Lavender, S., Merrill, J., Newton, J., Turpie, K., Canonico, G., & Tamburri, M. (2018). Alliance for Coastal Technologies Workshop Proceedings: Hyperspectral Imaging of Coastal Waters. University of Hawaii at Manoa.
- [5] Shin, M. S., Shin, J. I., Kim, I. J., & Seo, Y. C. (2016). Correction method of hyperspectral imagery for analysis of coastal seabed material. *Journal of the Korean Association of Geographic Information Studies*, 19(2), 107-116.
- [6] Kim, T.-H., Min, J. E., Lee, H. M., Kim, K. J., & Yang, C.-S. (2024). Application of hyperspectral image for monitoring in coastal area with deep learning: A case study of green algae on artificial structure. *Journal of Marine Science and Engineering*, 12(11), 2042.
- [7] Freitas, S., Silva, H., Almeida, J. M., & Silva, E. (2019). Convolutional neural network target detection in hyperspectral imaging for maritime surveillance. *International Journal of Advanced Robotic Systems*, 16(3). DOI: 10.1177/1729881419842991.
- [8] Park, J. J., Park, K. A., Kim, T. S., Oh, S., & Lee, M. (2023). Aerial hyperspectral remote sensing detection for maritime search and surveillance of floating small objects. *Advances in Space Research*, 72(6), 2118-2136.
- [9] Seo, D., Lee, D., Park, S., & Oh, S. (2025). Hyperspectral image-based identification of maritime objects using convolutional neural networks and classifier models. *Journal of Marine Science and Engineering*, 13(1), 6. DOI: 10.3390/jmse13010006.
- [10] Consultative Committee for Space Data Systems. (2019). Low-complexity lossless and near-lossless multispectral and hyperspectral image compression (Recommended Standard CCSDS 123.0-B-2, Blue Book). Washington, DC: CCSDS.
- [11] Fuchs, M. H. P., & Demir, B. (2023). HySpecNet-11k: A large-scale hyperspectral dataset for benchmarking learning-based hyperspectral image compression methods. In *IGARSS 2023—IEEE International Geoscience and Remote Sensing Symposium* (pp. 1779-1782). IEEE. DOI: 10.1109/IGARSS52108.2023.10283385.
- [12] Fuchs, M. H. P., Rasti, B., & Demir, B. (2024). HyCoT: A transformer-based autoencoder for hyperspectral image compression. arXiv:2408.08700.
- [13] Valsesia, D., Bianchi, T., & Magli, E. (2024). Onboard deep lossless and near-lossless predictive coding of hyperspectral images with line-based attention.

IEEE Transactions on Geoscience and Remote Sensing, 62, 1–14. DOI: 10.1109/TGRS.2024.3465043.

[14] Mdrafi, R., & Gurbuz, A. C. (2022). Data driven joint hyperspectral band selection and image classification. In IGARSS 2022–IEEE International Geoscience and Remote Sensing Symposium (pp. 1736–1739). IEEE. DOI: 10.1109/IGARSS46834.2022.9883821.

[15] Zhang, Y., Wang, X., Wang, Z., Jiang, X., & Zhou, Y. (2022). Graph learning based autoencoder for hyperspectral band selection. In ICASSP 2022–IEEE International Conference on Acoustics, Speech and Signal Processing (pp. 2794–2798). IEEE. DOI: 10.1109/ICASSP43922.2022.9747193.

[16] Samarathunga, P., Rezaei, H., Lokumarambage, M., Sivalingam, T., Rajatheva, N., & Fernando, A. (2024). An autoencoder-based task-oriented semantic communication system for M2M communication. Algorithms, 17(11), 492.

[17] Hong, S., Lee, D., Won, D., Noh, W., & Cho, S. (2025). Feature-importance-aware transmission control in semantic communications. ICT Express, 11(6), 1015–1020. DOI: 10.1016/j.ict.2025.11.

[18] Guo, C., Xi, J., He, Z., Liu, J., & Yang, J. (2024). A knowledge base driven task-oriented image semantic communication scheme. Remote Sensing, 16(21), 4044.

[19] Liu, F., Tong, W., Yang, Y., Sun, Z., & Guo, C. (2022). Task-oriented image semantic communication based on rate-distortion theory. arXiv:2201.10929.

[20] Beck, E., Bockelmann, C., & Dekorsy, A. (2023). Semantic information recovery in wireless networks. Sensors, 23(14), 6347.

[21] Zhang, X., Zhang, J. A., Liu, C., Yuan, W., Li, G. Y., & Amin, M. G. (2026). Semantic sensing: A task-oriented paradigm. arXiv:2603.29102.

[22] Grupo de Inteligencia Computacional, University of the Basque Country. (n.d.). Hyperspectral remote sensing scenes. Retrieved from https://www.ehu.eus/ccwintco/index.php/Hyperspectral_Remote_Sensing_Scenes.

[23] Headwall Photonics. (2019). Nano-Hyperspec VNIR imaging sensors data sheet.

[24] Specim. (2020). Specim AFX10 technical datasheet.

[25] DJI. (n.d.). DJI Transmission, DJI O3 Air Unit, and DJI O4 Air Unit specifications.

[26] Microhard Systems Inc. (n.d.). pDDL900 dual frequency OEM ethernet and serial digital data link specifications.

[27] Silvus Technologies. (n.d.). StreamCaster 4200 data sheet.

Abstract

A Mission-Aware Autoencoder Bottleneck Compression Framework for Drone-Based Hyperspectral Image Transmission

Anonymous Authors

Drone-based hyperspectral imagery can exploit material-specific spectral differences in naval missions such as littoral surveillance, harbor protection, camouflaged target detection, and maritime floating-object detection. However, hyperspectral imagery is represented as a three-dimensional cube containing spatial information and tens to hundreds of continuous spectral bands, making real-time transmission of the entire raw data from a drone to a ground station difficult. In particular, small drones are constrained by payload, power, onboard computing resources, and communication bandwidth, so transmitting all patches and bands with equal priority is operationally inefficient. To address this problem, this study examines a selective transmission framework that combines autoencoder-based latent representation compression with mission-aware patch selection. The proposed framework partitions a hyperspectral cube into spatial patches, selects high-priority patches under a limited transmission budget using random, edge_only, and spectral_only criteria, and transmits only the latent payloads of the selected patches. Three-seed experiments using the public KSC and Salinas datasets show that spectral_only achieves higher important precision and important recall than random and edge_only under several budget conditions. The latent payload also shows byte-reduction potential of approximately 613.0× for KSC and 710.5× for Salinas, reducing the payload size to a level transmittable within milliseconds over 40 Mbps and 100 Mbps links. This study reframes hyperspectral compression not as a simple reconstruction-quality problem, but as a problem of prioritizing mission-relevant information under constrained communication budgets.

Key words: hyperspectral image, autoencoder, UAV, mission-aware compression, selective transmission, littoral surveillance

논 문 투 고 일 :	논 문 심 사 일 :	게 재 확 정 일 :
2024.00.00	2024.00.00	2024.00.00